

实验分析报告

Sequence-Disjoint 条件下的
Graph-Valid Shuffle 与 Atomic-Tail 实验

M2-Direct-RealOrder、A1-Legacy 与 A3-DualPos 的系统比较

项目	内容
实验包	atomic_tail_sequence_disjoint_2026-08-24
评估协议	4-fold cross-person LOSO；每折 3 个随机种子（1、2、42）
完成规模	12 个 backbone/feature 任务 + 60 个 history-model 任务
报告日期	2026-08-25

本报告仅分析已完成的sequence-disjoint 实验；所有主结果均来自 actual chronological order 测试。

执行摘要

核心结论 在严格移除训练集中与测试对象完全同序的真实 run 后，A1-Legacy-Once 取得最好的综合结果：Tier3 All Accuracy 为 85.46%，比 M2-Direct-RealOrder 高 1.58 个百分点。

边界条件 优势不是跨参与者一致的：A、D 两折受益，J、M 两折轻微下降；All 的 12 个配对结果为 7 胜、1 平、4 负。因此证据支持“平均上有帮助”，但不足以宣称对所有未知顺序稳定占优。

刷新策略 A1 Every10 虽覆盖了更多测试历史前缀，但 All Accuracy 比 A1 Once 低 0.89 个百分点；更多顺序多样性没有自动转化为更高泛化性能。

DualPos A3-DualPos-Once 与 Every10 的 All Accuracy 均约 82.6%，低于 M2 约 1.2 个百分点。由于它同时改变了增强范围和位置语义，本轮不能把差异单独归因于 DualPos 编码。

按平均性能排序，Normal 与 All 的最佳模型都是 A1-Legacy-Once；Fault 的最佳模型是 A1-Legacy-Every10-Replace。Fault 样本量更小且跨参与者波动更大，相关提升应谨慎解释。

1. 研究问题与实验逻辑

1.1 要验证的主张

本轮实验希望回答：当测试 run 的完整动作顺序从未作为真实训练 run 出现时，graph-valid shuffle augmentation 是否能够通过生成新的合法历史顺序，使历史融合模型优于只使用真实训练顺序的 M2-Direct baseline。

这里的关键不是禁止增强结果碰到测试顺序。增强器可以自然生成与测试相同的顺序，因为这正是顺序增强希望获得的泛化覆盖；唯一禁止的是增强器读取、定位或针对测试顺序进行采样。

1.2 公平比较原则

所有五个历史模型共享同一 fold×seed 下重新训练的视觉 backbone 与新提取的 512 维特征；M2 始终使用真实历史顺序且不 shuffle；四种增强模型只在训练视图上改变历史顺序；测试统一使用真实 chronological order。

2. 数据隔离协议

2.1 顺序定义与过滤规则

每个 run 按 annotation_row_index 排序，并以完整 node_idx 元组作为签名；连续重复节点不折叠。若一个训练 run 的完整签名与该折 test_all 中任一 run 完全一致，则移除整个训练 run。Tier3 顺序只用于审计，不参与过滤。

Test fold	原 train runs	保留 runs	移除 runs	移除比例	保留 clips	N/F/All clips	剩余重叠
A	79	27	52	65.8%	623	294/137/431	0
D	78	38	40	51.3%	869	400/62/462	0
J	73	33	40	54.8%	698	387/168/555	0
M	79	32	47	59.5%	681	360/87/447	0

表1 Sequence-disjoint 过滤规模。四折均保持35 个Node 与31 个Tier3 类别完整覆盖。

过滤强度很大：每折移除了 40–52 个训练 run，保留 27–38 个 run。A fold 仅保留 623 个训练 clips，是数据缩减最明显的一折，也正是增强收益最大的一折。这个对应关系值得注意，但不能据此直接证明因果。

3. 实验配置与模型含义

3.1 上游视觉模型与特征

每个 fold×seed 均在过滤后的 all-runs train manifest 上从头训练 R3D-18 Tier3 classifier。实际训练日志确认全部为 100 epochs；batch size 16，AdamW，初始学习率 1e-4，weight decay 1e-4，AMP 开启；学习率在第 50、75 轮后各衰减 10 倍。随后使用 last checkpoint 分别提取过滤 train 与完整 test_all 的 512-D 特征。旧 checkpoint 与旧 feature cache 均未复用。

3.2 历史融合模型

历史模型共同配置为：feature_dim 512、d_model 256、4 个 attention heads、最大历史 35、dropout 0.1；35 个 Node 输出并聚合为 31 个 Tier3 类别。每个模型从头训练 50 epochs，batch size 64，AdamW，学习率 1e-3，weight decay 1e-4，gradient clip 1.0，关闭 AMP，确定性训练。

模型	训练顺序	位置语义	增强范围	刷新	实验含义
M2 RealOrder	真实顺序	presented	无	无	历史信息+真实顺序 基线；严禁 shuffle
A1 Once	广义 graph-valid	先 shuffle 后赋 presented 位置	非 active-tail 也可增 强	仅一次	整个训练保持固定增 强视图
A1 Every10	广义 graph-valid	先 shuffle 后赋 presented 位置	非 active-tail 也可增 强	每 10 轮替 换	轮次 0/1/2/3/4；模 型、位置嵌入、优化 器连续
DualPos Once	graph-valid	真实 recency+位移 embedding	仅 active atomic tail	仅一次	保留真实时间距离并 编码呈现位移
DualPos Every10	graph-valid	真实 recency+位移 embedding	仅 active atomic tail	每 10 轮替 换	同一模型连续学习多 轮增强视图

表 2 五种历史模型的核心差异。

4. 完整性与运行审计

审计项	结果	说明
Sequence-disjoint folds	4/4	exact full-run overlap=0；类别支持完整
Backbone checkpoints	12/12	每个 fold×seed 从头训练 100 轮
Feature caches	12/12	train_all.pt 与 test_all.pt 及 metadata 齐全
History jobs	60/60	5 模型×4 folds×3 seeds；均 50 轮
测试指标	180/180	60 jobs×normal/fault/all；actual chronological order

配置核对 实验包配置与实际日志一致地显示 backbone=100 epochs。本报告采用实际训练日志作为最终事实来源。

5. 上游 Backbone 性能

Split	Tier3 Accuracy	Macro-F1	Balanced Accuracy
Normal	75.18 ± 6.61	75.88 ± 5.20	78.13 ± 5.01
Fault	74.54 ± 8.60	71.59 ± 8.42	75.15 ± 7.10
All	74.49 ± 6.45	75.25 ± 4.20	77.06 ± 3.65

表 3 R3D-18 last-checkpoint 性能, 均值±样本标准差基于 12 个 fold×seed 结果。

Backbone 的 All Accuracy 为 74.49%，而 M2 历史融合达到 83.89%，说明在本协议下历史上下文带来约 9.40 个百分点的整体增益。该差值用于描述上下文价值，不应被解释为严格的独立模型显著性比较。

6. 历史模型主结果

6.1 Tier3 总体结果

模型	N Acc	N F1	F Acc	F F1	All Acc	All F1
M2 RealOrder	85.17 ± 6.43	83.62 ± 5.21	81.64 ± 10.28	78.53 ± 9.57	83.89 ± 7.16	82.82 ± 4.90
A1 Once	86.56 ± 4.55	84.59 ± 4.18	83.32 ± 8.28	79.17 ± 7.82	85.46 ± 5.11	83.61 ± 3.10
A1 Every10	85.49 ± 4.35	84.05 ± 4.79	83.60 ± 8.31	80.05 ± 7.70	84.58 ± 4.79	83.24 ± 3.60
DualPos Once	83.59 ± 6.76	83.06 ± 5.91	81.11 ± 10.04	77.66 ± 9.65	82.63 ± 7.38	82.17 ± 5.51
DualPos Every10	83.37 ± 7.08	81.47 ± 4.99	81.89 ± 10.03	78.71 ± 7.94	82.67 ± 7.61	81.18 ± 4.71

表 4 Tier3 性能 (%) , 均值±样本标准差, n=12 fold×seed。粗体未用于标记显著性; 最佳均值见正文。

Tier3 Accuracy: 五种历史模型的总体比较




图1 Tier3 Accuracy 总体比较。Normal/All 由 A1 Once 最高，Fault 由 A1 Every10 最高。

A1-Legacy-Once 在 Normal、Fault、All 的 Accuracy 分别为 86.56%、83.32%、85.46%；相比 M2 分别提高 1.38、1.68、1.58 个百分点。A1 Every10 在 Fault 上达到 83.60%，是该 split 最佳，但在 Normal 与 All 上低于 A1 Once。

DualPos 两组在 Normal 与 All 上均低于 M2。DualPos Every10 的 Fault Accuracy 略高于 M2 0.25 个百分点，但其 Fault Macro-F1 仅高 0.18 个百分点，且跨 seed/participant 表现并不一致。

6.2 Node-level 结果

模型	N Acc	N F1	F Acc	F F1	All Acc	All F1
M2 RealOrder	85.05 ± 6.49	83.68 ± 5.34	81.21 ± 10.72	78.49 ± 10.49	83.67 ± 7.30	82.77 ± 5.48
A1 Once	86.55 ± 4.54	84.89 ± 4.17	83.06 ± 8.22	79.43 ± 8.22	85.39 ± 5.08	83.86 ± 3.50
A1 Every10	85.05 ± 4.52	83.92 ± 4.77	83.06 ± 8.40	79.94 ± 8.15	84.10 ± 4.81	83.07 ± 3.93
DualPos Once	83.02 ± 7.15	82.56 ± 6.41	79.85 ± 11.00	77.06 ± 10.95	81.86 ± 7.95	81.53 ± 6.50
DualPos Every10	82.95 ± 7.73	81.25 ± 5.83	81.12 ± 11.27	78.34 ± 9.93	82.15 ± 8.43	80.84 ± 6.06

表5 Node-level 性能 (%)，均值±样本标准差，n=12。

Node-level 与 Tier3 的结论一致：A1 Once 在 All 上达到 85.39% Accuracy，比 M2 的 83.67% 高 1.72 个百分点；DualPos Once/Every10 分别为 81.86%/82.15%。因此主结论不是由 Node 到 Tier3 映射方式单独造成。

6.3 相对 M2 的配对差值

模型	ΔN Acc	ΔF Acc	ΔAll Acc	All seed W/T/L	All fold W/T/L
A1 Once	+1.38	+1.68	+1.58	7/1/4	2/0/2
A1 Every10	+0.31	+1.96	+0.69	7/1/4	3/0/1
DualPos Once	-1.59	-0.54	-1.26	3/0/9	1/0/3
DualPos Every10	-1.81	+0.24	-1.21	4/0/8	1/0/3

表6 相对同 fold、同 seed M2 的 Tier3 Accuracy 差值 (百分点) 。W/T/L 为胜/平/负。

相对 M2 的 Tier3 Accuracy 变化 (百分点)



绿色表示优于 M2，红色表示低于 M2；数值为12个 fold×seed 配对差值的均值。

图2 四种增强模型相对M2 的平均配对差值。

统计解释 3 个 seed 共享同一 held-out participant 和测试样本，不能视为 12 个完全独立实验单位。真正的跨人独立单位只有 4 折，因此本报告以描述性均值、配对差值和胜负分布为主，不做夸大的显著性声明。

7. 跨参与者与分阶段分析

7.1 Fold heterogeneity




图3 All split 中每个 held-out participant 的3-seed 平均Tier3 Accuracy。

表7 Normal：按fold 的3-seed 平均Tier3 Accuracy (%)。

Normal / 模型	A	D	J	M
M2 RealOrder	78.80	83.42	94.32	84.17
A1 Once	83.22	86.17	92.76	84.07
A1 Every10	82.31	83.50	92.16	83.98
DualPos Once	75.06	85.42	91.47	82.41
DualPos Every10	74.49	84.75	91.82	82.41

表8 Fault：按fold 的3-seed 平均Tier3 Accuracy (%)。

Fault / 模型	A	D	J	M
M2 RealOrder	65.45	86.02	88.89	86.21
A1 Once	71.05	87.10	90.08	85.06
A1 Every10	70.80	88.17	87.70	87.74
DualPos Once	65.45	88.17	86.51	84.29

Fault / 模型	A	D	J	M
DualPos Every10	67.64	88.71	86.90	84.29

表9 All: 按fold 的3-seed 平均Tier3 Accuracy (%)。

All / 模型	A	D	J	M
M2 RealOrder	74.56	83.77	92.67	84.56
A1 Once	79.35	86.29	91.95	84.27
A1 Every10	78.65	84.13	90.81	84.71
DualPos Once	72.00	85.79	89.97	82.77
DualPos Every10	72.31	85.28	90.33	82.77

A1 Once 的主要收益来自 A 与 D: All 分别比 M2 高 4.80 和 2.53 个百分点; J 与 M 分别低 0.72 和 0.30 个百分点。J fold 的 M2 基线已经达到 92.67%, 增强后略降, 呈现明显的高基线/潜在天花板特征。

A fold 的 M2 All Accuracy 仅 74.56%, A1 Once 提升至 79.35%; 该折训练集过滤最强、保留 clips 最少。这个现象与“顺序增强在顺序覆盖不足时更有价值”的假设一致, 但只有一个最强过滤折, 尚不足以建立稳健关联。

7.2 Stage-level 结果

模型	Stage 1 Acc	Stage 2 Acc	Stage 3 Acc
M2 RealOrder	81.74 ± 6.29	83.72 ± 9.23	86.02 ± 5.59
A1 Once	81.79 ± 6.85	85.87 ± 6.92	86.32 ± 4.24
A1 Every10	82.05 ± 7.29	84.54 ± 6.46	86.79 ± 4.30
DualPos Once	80.86 ± 6.32	82.18 ± 9.57	86.20 ± 5.94
DualPos Every10	79.75 ± 7.29	82.75 ± 10.30	84.30 ± 6.88

表10 test_all 的stage-level Tier3 Accuracy (% , 12 个fold×seed 均值±SD)。

A1 Once 的增益主要集中在 Stage 2: 85.87% 对 M2 的 83.72%, 提高 2.15 个百分点; Stage 1 和 3 基本持平。Stage 2 包含动作密度更高、顺序分支更多的主体操作段, 这与 graph-valid 顺序增强的目标相符。

8. 增强行为与顺序覆盖

8.1 实际训练视图的改变强度

模型	Changed histories	Mean Kendall	Shifted tokens	Mean abs shift
M2 RealOrder	0.00	0.000	0.00	0.000
A1 Once	53.43	0.117	0.00	0.000
A1 Every10	53.43	0.117	0.00	0.000
DualPos Once	29.73	0.050	22.96	0.810
DualPos Every10	29.73	0.050	22.96	0.810

表 11 训练时 augmentation audit 的 12 任务均值 (%或表中标注尺度)。

A1 的约 53.43%训练历史发生变化，DualPos 约 29.73%。A1 的 shifted-token 指标为 0 并不是没有 shuffle：它在重排后重新赋 presented 位置，因此没有“相对真实位置的位移 embedding”；DualPos 则显式记录位移，约 22.96%的历史 token 具有非零 shift。

8.2 Post-hoc 测试前缀覆盖审计

模型	Changed	Actual coverage	Augmented coverage	新覆盖前缀总数
A1 Once	55.97	19.66	19.15	16
A1 Every10	56.13	19.66	22.68	34
DualPos Once	31.15	19.66	19.66	2
DualPos Every10	31.13	19.66	20.20	6

表 12 四折 post-hoc coverage 均值；最后一列为四折新覆盖测试前缀数之和。

增强强度与测试历史前缀覆盖（四折均值）




图 4 增强改变比例与测试历史前缀覆盖。该审计不参与采样，不构成测试泄漏。

A1 Every10 将平均 augmented prefix coverage 提高到 22.68%，并累计新覆盖 34 个测试前缀，高于 A1 Once 的 19.15%与 16 个。然而其 All Accuracy 反而低 0.89 个百分点。这表明覆盖数量不是充分条件：频繁替换可能增加优化噪声，或生成的额外前缀与判别边界并不匹配。

coverage 的比较单位是“当前 clip 之前的 node-order 历史前缀”，而不是一条连贯合成的完整 run。Legacy augmenter 按样本独立重排历史，因此不能把这些覆盖数字解释为生成了同等数量的完整新流程。

9. Once 与 Every10 的直接比较

比较	Split	平均ΔAcc	Seed W/T/L	Fold 均值差值
A1 Every10 - Once	Normal	-1.07	3/0/9	A:-0.91 D:-2.67 J:-0.60 M:-0.09
A1 Every10 - Once	Fault	+0.28	7/0/5	A:-0.24 D:+1.08 J:-2.38 M:+2.68
A1 Every10 - Once	All	-0.89	3/1/8	A:-0.70 D:-2.16 J:-1.14 M:+0.45
DualPos Every10 - Once	Normal	-0.22	5/0/7	A:-0.57 D:-0.67 J:+0.34 M:+0.00
DualPos Every10 - Once	Fault	+0.78	6/2/4	A:+2.19 D:+0.54 J:+0.40 M:+0.00
DualPos Every10 - Once	All	+0.04	5/0/7	A:+0.31 D:-0.51 J:+0.36 M:+0.00

表 13 Every10 减Once 的Tier3 Accuracy 配对差值（百分点）。

A1 Every10 对 Fault 有+0.28 个百分点的轻微平均收益，但 Normal/All 分别为-1.07/-0.89；All 中仅 3 胜、1 平、8 负。DualPos Every10 与 Once 的 All 几乎相同 (+0.04)，主要表现为 Fault 稍升、Normal 稍降。

因此，本轮没有证据支持“每 10 轮替换一定优于只 shuffle 一次”。更稳妥的解释是：A1 的固定增强视图更容易优化，而 DualPos 对刷新频率不敏感。

10. 对研究假设的回答

10.1 能否证明 graph-valid shuffle 优于 M2？

回答 可以给出有限度、模型特定的支持：A1-Legacy-Once 在严格 sequence-disjoint 条件下取得最高总体均值，并在 Normal、Fault、All 三个 split 都高于 M2；但优势集中于部分参与者，不能写成无条件的普遍优越性。

最合适的论文式表述是：‘Under exact full-run sequence disjointness, legacy graph-valid shuffle with post-shuffle presented-position encoding improved mean Tier3 accuracy over the real-order M2 baseline by 1.58 percentage points on the combined test split, although gains were participant-dependent.’

10.2 哪个模型最适合作为当前主方法？

当前主方法应选 A1-Legacy-Once。它既实现了训练时新顺序暴露，又避免保留真实 recency 对原顺序的显式提示；同时在三个 split 上均给出正向平均增益。A1 Every10 可作为 Fault-oriented 消融，而不宜替代 Once 作为总体最佳配置。

10.3 为什么 DualPos 没有体现优势？

第一，DualPos 只增强 active atomic tail，实际改变历史比例约为 A1 的一半；第二，它保留真实 recency，模型仍能读取原始时间关系，shuffle 对顺序不变性的训练压力更弱；第三，A1 与 DualPos 同时在增强范围和位置编码上不同，本轮不是干净的单因素比较。因此只能说‘当前 DualPos 组合无效’，不能断言‘位移编码本身无效’。

11. 局限性与后续实验建议

11.1 主要局限

独立跨人单位仅 4 个；seed 重复主要刻画训练随机性，不能替代更多参与者。Fault 样本按 fold 差异明显（62–168），导致 Fault 均值波动较大。Sequence-disjoint 过滤移除了大量训练数据，因此结果同时反映了‘顺序未见’和‘训练样本减少’两个因素。

此外，测试前缀覆盖是 post-hoc 诊断指标，并不衡量生成顺序的任务相关性或样本权重；A1 与 DualPos 的比较还混合了 active-tail scope 和 position semantics。

11.2 优先建议

第一优先：补做 2x2 消融，将 shuffle scope (broad vs active-tail-only) 与 position semantics (presented vs true+shift) 正交化。至少加入 broad-shuffle DualPos 与 active-tail presented-position 两个模型。

第二优先：保留 A1 Once 作为主方法，针对每折统计训练实际顺序数量、增强后 unique prefixes、A1 增益之间的相关趋势；若参与者增加，再进行以 participant 为单位的置信区间或层级模型分析。

第三优先：Every10 不再作为默认增强策略。若继续研究刷新频率，建议增加 Every20 或 curriculum 式刷新，并记录每次刷新前后的训练损失跳变，以区分覆盖收益与优化扰动。

第四优先：增加一个‘不做 sequence 过滤但保持同等训练 run 数量’的下采样控制，用于拆分顺序隔离效应与数据量下降效应。

附录 A：逐 fold、逐 seed Tier3 Accuracy

模型	Fold	Seed 1	Seed 2	Seed 42	Mean
M2 RealOrder	A	77.21	78.23	80.95	78.80
M2 RealOrder	D	80.00	88.50	81.75	83.42
M2 RealOrder	J	95.61	94.83	92.51	94.32
M2 RealOrder	M	86.11	80.83	85.56	84.17
A1 Once	A	82.99	83.67	82.99	83.22
A1 Once	D	86.25	86.75	85.50	86.17
A1 Once	J	96.64	93.80	87.86	92.76
A1 Once	M	86.11	85.56	80.56	84.07
A1 Every10	A	81.97	82.65	82.31	82.31
A1 Every10	D	82.00	84.00	84.50	83.50
A1 Every10	J	89.41	94.32	92.76	92.16
A1 Every10	M	85.83	81.67	84.44	83.98
DualPos Once	A	77.55	73.47	74.15	75.06
DualPos Once	D	81.25	85.25	89.75	85.42
DualPos Once	J	94.57	92.25	87.60	91.47
DualPos Once	M	83.89	79.44	83.89	82.41
DualPos Every10	A	78.23	70.75	74.49	74.49
DualPos Every10	D	86.25	79.00	89.00	84.75
DualPos Every10	J	92.76	91.99	90.70	91.82
DualPos Every10	M	81.94	84.72	80.56	82.41

表14 Normal split 逐 fold、逐 seed Tier3 Accuracy (%)。

模型	Fold	Seed 1	Seed 2	Seed 42	Mean
M2 RealOrder	A	64.23	62.04	70.07	65.45
M2 RealOrder	D	83.87	87.10	87.10	86.02
M2 RealOrder	J	89.29	89.29	88.10	88.89
M2 RealOrder	M	91.95	81.61	85.06	86.21
A1 Once	A	72.26	73.72	67.15	71.05
A1 Once	D	90.32	85.48	85.48	87.10
A1 Once	J	88.69	91.07	90.48	90.08
A1 Once	M	91.95	81.61	81.61	85.06
A1 Every10	A	65.69	74.45	72.26	70.80
A1 Every10	D	87.10	87.10	90.32	88.17
A1 Every10	J	85.71	87.50	89.88	87.70
A1 Every10	M	93.10	86.21	83.91	87.74
DualPos Once	A	65.69	67.88	62.77	65.45
DualPos Once	D	90.32	85.48	88.71	88.17
DualPos Once	J	85.71	90.48	83.33	86.51
DualPos Once	M	89.66	79.31	83.91	84.29
DualPos Every10	A	74.45	57.66	70.80	67.64
DualPos Every10	D	93.55	83.87	88.71	88.71
DualPos Every10	J	87.50	88.69	84.52	86.90
DualPos Every10	M	89.66	83.91	79.31	84.29

表15 Fault split 逐fold、逐seed Tier3 Accuracy (%)。

模型	Fold	Seed 1	Seed 2	Seed 42	Mean
M2 RealOrder	A	73.09	73.09	77.49	74.56
M2 RealOrder	D	80.52	88.31	82.47	83.77
M2 RealOrder	J	93.69	93.15	91.17	92.67
M2 RealOrder	M	87.25	80.98	85.46	84.56
A1 Once	A	79.58	80.51	77.96	79.35
A1 Once	D	86.80	86.58	85.50	86.29
A1 Once	J	94.23	92.97	88.65	91.95
A1 Once	M	87.25	84.79	80.76	84.27
A1 Every10	A	76.80	80.05	79.12	78.65
A1 Every10	D	82.68	84.42	85.28	84.13
A1 Every10	J	88.29	92.25	91.89	90.81
A1 Every10	M	87.25	82.55	84.34	84.71
DualPos Once	A	73.78	71.69	70.53	72.00
DualPos Once	D	82.47	85.28	89.61	85.79
DualPos Once	J	91.89	91.71	86.31	89.97
DualPos Once	M	85.01	79.42	83.89	82.77
DualPos Every10	A	77.03	66.59	73.32	72.31
DualPos Every10	D	87.23	79.65	88.96	85.28
DualPos Every10	J	91.17	90.99	88.83	90.33
DualPos Every10	M	83.45	84.56	80.31	82.77

表16 All split 逐fold、逐seed Tier3 Accuracy (%)。

附录 B：指标定义与汇总口径

Accuracy 为正确预测样本比例；Macro-F1 对当前 split 中被评估类别的 F1 做等权平均；Balanced Accuracy 对各类别召回率做等权平均。Node-level 针对 35 个图节点，Tier3-level 针对 31 个动作类别。

正文的‘均值±SD’以 12 个 fold×seed 记录计算，便于与既有实验汇总保持一致；fold 表先对 3 个 seed 求均值，更适合观察跨人的方向一致性。All 并非 Normal 与 Fault 指标的简单算术平均，而是在合并样本上重新计算。分析源包括 sequence-disjoint 与 coverage 总审计、12 组 backbone 日志、60 组 history 任务及 180 个 split metrics。